FPT UNIVERSITY
DATA SCIENCE METHODOLOGY

Quy Trình 10 Bước
Phân Tích SQL & Python

- **6.607 Bản Ghi Sinh Viên**
- **16 Thuộc Tính**
- **14 Truy Vấn SQLite**
- **Kiểm Định & Hồi Quy**

Bảo Vệ Đồ Án Cuối Kỳ
Phân Tích Kết Quả Học Tập Sinh Viên

Môn học: Data Science with Python & SQL (ADY201m)
Bộ dữ liệu: StudentPerformanceFactors.csv (6.607 dòng × 16 cột)

Các Hạng Mục Trọng Tâm Trong Đồ Án

- Quy trình 10 bước chuẩn FPT: Từ đặt mục tiêu -> Làm sạch SQL/Python -> Mô hình -> Triển khai.
- Làm sạch dữ liệu trên bảng mới: CTE + ROW_NUMBER(), đánh dấu NULL điểm 101 vượt thang đo.
- Phân tích khám phá (EDA): 7 biểu đồ trực quan, kiểm tra IQR Outliers và tương quan Pearson.
- Kiểm định & Mô hình hóa: Phân nhóm SQL Window Functions, kiểm định ANOVA/T-test & Hồi quy tuyến tính.

01

AGENDA

Nội Dung Trình Bày

01. Đặt Mục Tiêu & Hướng Tiếp Cận

• Xác định vấn đề, 3 câu hỏi nghiên cứu và phương pháp SQL + Python.

02. Yêu Cầu & Thu Thập Dữ Liệu SQL

• 6.607 sinh viên, 16 cột, tạo khóa student_id từ rowid, truy vấn SQL.

03. Kiểm Tra & Làm Sạch Dữ Liệu

• Điền 'Unknown' cho ô thiếu và đánh dấu NULL bản ghi điểm 101.

04. Phân Tích Khám Phá Dữ Liệu (EDA)

• Phân phối điểm thi, dò tìm IQR Outliers và ma trận tương quan.

05. Phân Tích Biến Phân Loại

• Biểu đồ Violin/Boxplot cho Gia đình, Nhà trường, Bạn bè & Nhân khẩu học.

06. Mô Hình Phân Nhóm Quy Tắc SQL

• CASE WHEN chia nhóm giờ học, hàm RANK() OVER và nhóm chuyên cần.

07. Kiểm Định ANOVA & Hồi Quy Đa Biến

• 8/10 biến phân loại có ý nghĩa ($p < 0,001$) & Hồi quy $R^2 = 60,8\%–68,4\%$.

08. Đánh Giá, Triển Khai & Khuyến Nghị

• Truy vấn CTE + JOIN, đối chiếu SQL/Python, xuất CSV/DB & giải pháp.

Bám sát sơ đồ 10 bước Khoa học Dữ liệu, tập trung trình bày chuyên sâu các Bước 4 đến Bước 8.

02

STEPS 1 TO 3 — METHODOLOGY

Bước 1–3: Đặt Mục Tiêu, Hướng Tiếp Cận & Yêu Cầu Dữ Liệu

Bước 1: Đặt Mục Tiêu (Business Understanding)

- Vấn đề: Xác định các yếu tố học tập và hoàn cảnh đi cùng điểm thi (Exam_Score) cao/thấp.
- Câu hỏi 1: Điểm thi trung bình là bao nhiêu (67,23) và chất lượng dữ liệu thế nào?
- Câu hỏi 2: Các nhóm giờ tự học/tuần và tỷ lệ chuyên cần có điểm khác nhau ra sao?
- Câu hỏi 3: Động lực, sự tham gia/học vấn phụ huynh và ngoại khóa tương tác thế nào?

Bước 2: Hướng Tiếp Cận (SQL + Python)

- SQL (SQLite): Kiểm tra chất lượng, làm sạch trên bảng mới (CTE + ROW_NUMBER), phân nhóm CASE WHEN, Window Functions (RANK, SUM OVER) và CTE + JOIN.
- Python (Pandas, SciPy, Scikit-learn): Đối chiếu chéo kết quả SQL, phát hiện IQR Outliers, kiểm định ANOVA/T-test và Hồi quy tuyến tính.

Bước 3: Xác Định Dữ Liệu Cần Dùng (6.607 Bản Ghi × 16 Cột)

- Khóa định danh: Dữ liệu gốc không có cột khóa -> tạo student_id = rowid (tương ứng chỉ số dòng 1..6607).
- 6 Biến số: Exam_Score (mục tiêu, 0–100), Hours_Studied (1–44h), Attendance (60–100%), Previous_Scores (50–100), Sleep_Hours (4–10h), Physical_Activity (0–6h).
- 10 Biến phân loại: Parental_Involvement, Access_to_Resources, Motivation_Level, Family_Income, Teacher_Quality (thiếu 78 ô), Peer_Influence, Parental_Education_Level (thiếu 90 ô), Extracurricular_Activities, School_Type, Gender.

Triển khai song song bằng SQL và Python giúp đối chiếu chéo và đảm bảo độ tin cậy tuyệt đối.

03

STEPS 4 TO 6 — DATA PREPARATION

Bước 4–6: Truy Xuất, Kiểm Tra Chất Lượng & Làm Sạch Dữ Liệu

Bước 4 & 5: Truy Xuất & Kiểm Tra Chất Lượng

- Nạp 6.607 dòng từ CSV vào bảng SQLite raw_students.
- Truy vấn 4.1 (Top 10 chuyên cần >= 90%): Phát hiện student_id = 1526 có Exam_Score = 101.
- Truy vấn 4.2 (Loại trường × Giới tính): Trường công (4.598 SV, TB ~67,21) và Trường tư (2.009 SV, TB ~67,29) — khớp 100% với Pandas.
- Kiểm tra lỗi: 0 dòng trùng | Thiếu 78 ô Teacher_Quality | Thiếu 90 ô Parental_Education | 1 điểm > 100.

Bước 6: Quy Tắc Làm Sạch Trên Bảng Mới (Trọng Tâm)

- Tạo bảng mới students_clean_sql & DataFrame clean_py (không sửa bảng gốc).
- Quy tắc 1 & 2: Tạo khóa student_id = rowid (1..6607); chuẩn hóa snake_case & TRIM().
- Quy tắc 3: Điền 'Unknown' cho 78 ô thiếu Teacher_Quality và 90 ô thiếu Parental_Education.
- Quy tắc 4: Đánh dấu Exam_Score = 101 thành NULL (không tự ý sửa điểm thi).
- Quy tắc 5: Khử trùng lặp bằng ROW_NUMBER() OVER (PARTITION BY ...) = 1.

Bảng Đối Chiếu Trước & Sau Khi Làm Sạch (SQL Khớp Python 100%)

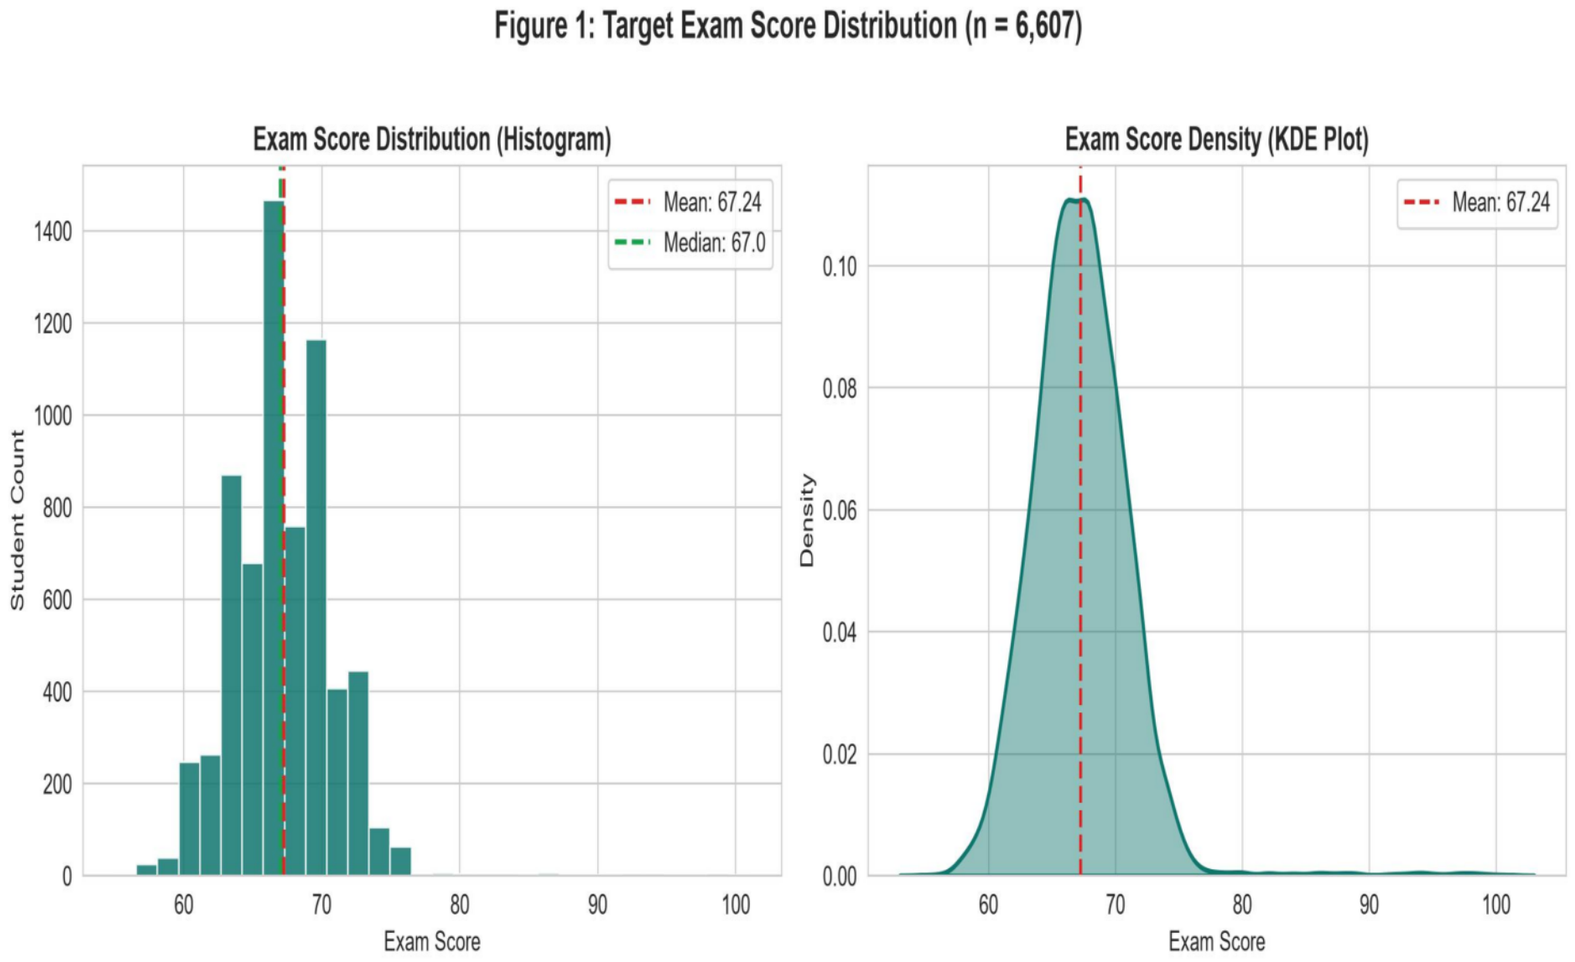
- Số bản ghi: 6.607 dòng gốc -> 6.607 dòng sạch (trong đó có 6.606 điểm thi hợp lệ từ 55–100 và 1 bản ghi điểm 101 được đánh dấu NULL).
- Xử lý ô thiếu: 168 ô trống (78 ở Teacher_Quality + 90 ở Parental_Education_Level) -> 0 ô trống (chuyển thành nhãn 'Unknown').
- Điểm trung bình hợp lệ: 67,236 (trước làm sạch) -> 67,231 (sau làm sạch, khớp tuyệt đối giữa SQLite và Pandas).

Bước 6 đảm bảo dữ liệu sạch đồng nhất 100% giữa bảng SQL students_clean_sql và Python clean_py.

04

EXPLORATORY DATA ANALYSIS

Phân Phối Điểm Thi & Kiểm Tra Giá Trị Ngoại Lai (IQR)



Nhận Xét Phân Phối

- Trung bình: 67,24 | Trung vị: 67,0.
- Độ lệch chuẩn: 3,89 | IQR: 4,0 (Q1=65, Q3=69).
- Miền hợp lệ: 55–100 điểm (1 dòng 101 -> NULL).
- Phân phối lệch phải (Skewness = 1,645) do nhóm sinh viên giỏi đạt 76–100 điểm.
- Phát hiện Outliers (IQR):
  - Hours_Studied: 43 (0,65%)
  - Exam_Score: 104 (1,57%)
  - 4 biến số còn lại: 0%

Đa số sinh viên đạt điểm trong khoảng 65–69, có đuôi phân phối lệch phải ở nhóm điểm cao.

05

EXPLORATORY DATA ANALYSIS

Mối Quan Hệ Giữa Giờ Học, Điểm Danh & Ma Trận Tương Quan

Figure 2: Relationship Between Study Hours, Attendance, and Exam Score

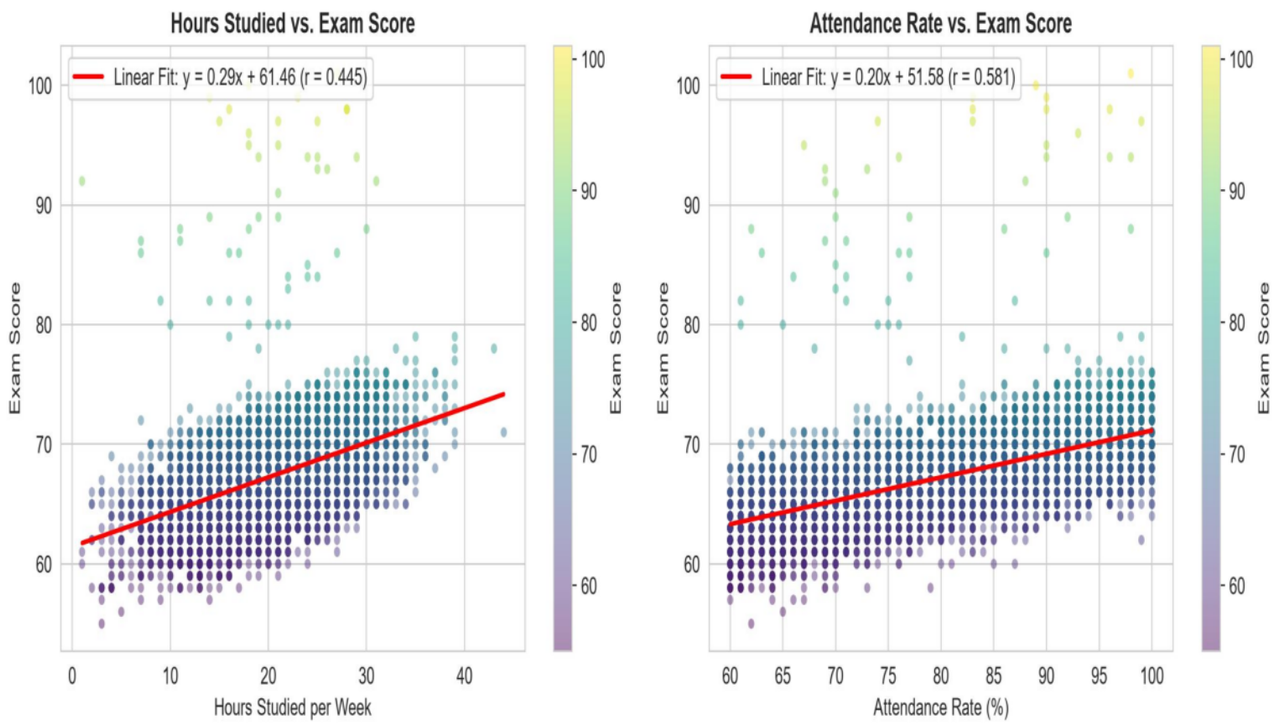
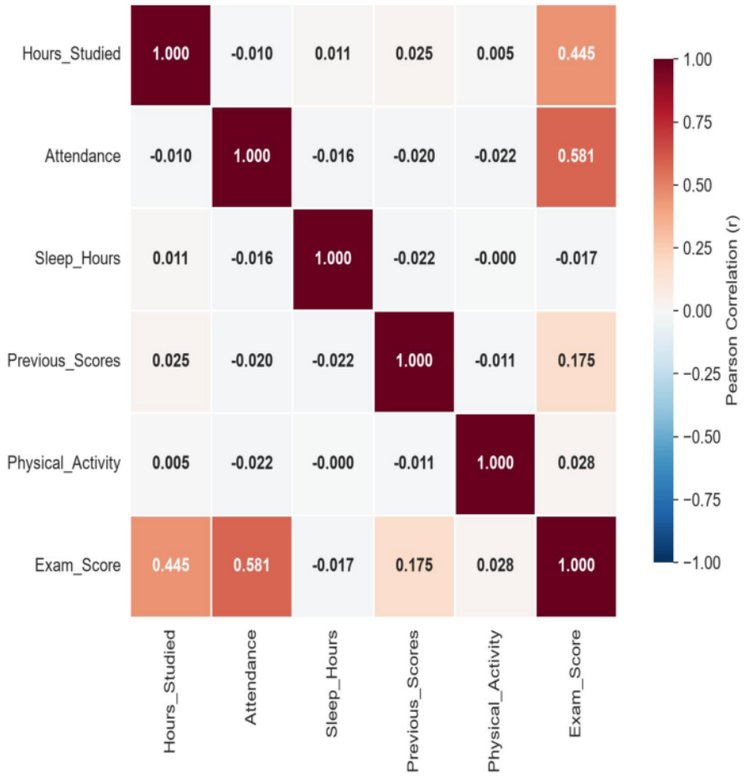


Figure 3: Pearson Correlation Matrix of Numerical Variables



Kết quả chính: Điểm danh (r = 0,581) và Giờ tự học (r = 0,445) tương quan thuận mạnh nhất với Điểm thi; Điểm quá khứ (r = 0,175) đứng thứ ba.

Số giờ ngủ (r = -0,017) và Hoạt động thể chất (r = 0,028) gần như không tương quan tuyến tính với Điểm thi.

06

EXPLORATORY DATA ANALYSIS

Ảnh Hưởng Của Các Yếu Tố Phân Loại & Nhân Khẩu Học

Figure 4: Impact of Key Categorical Factors on Exam Score (ANOVA p < 0.001)

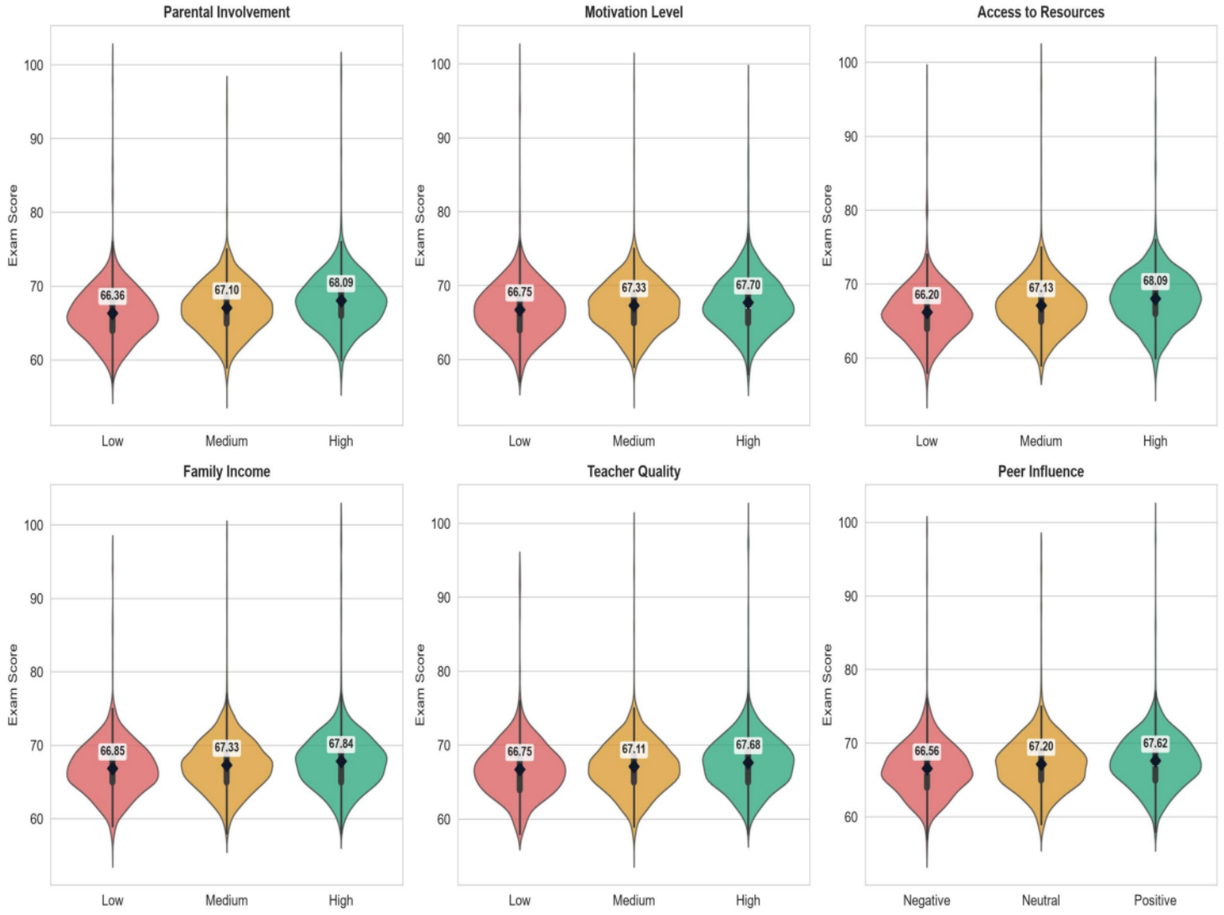
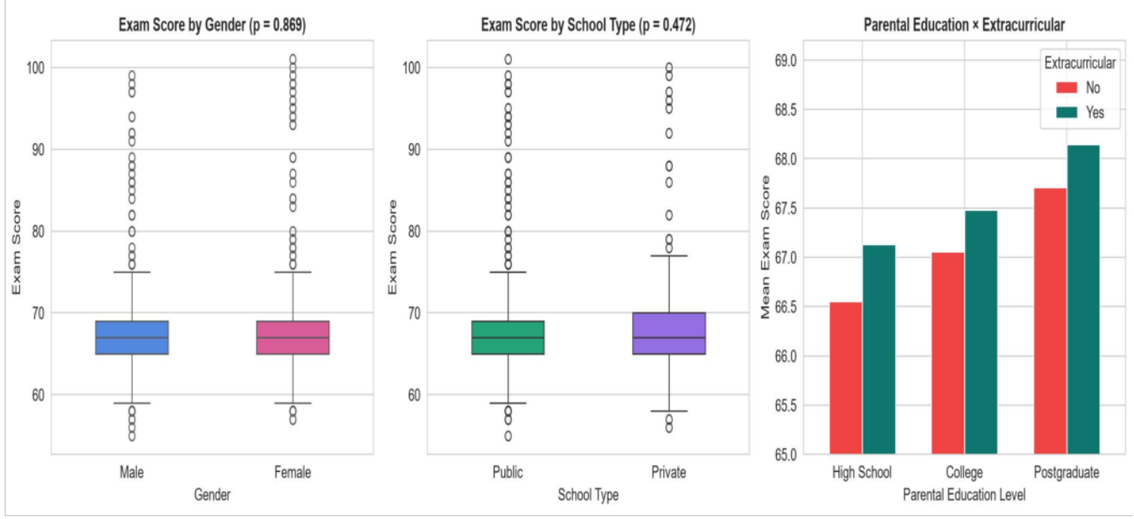


Figure 5: Score Comparison Across Demographics and Extracurricular Participation



So Sánh Các Biến Phân Loại

- Ảnh hưởng rõ rệt (p < 0,001): Tiếp cận tài nguyên (+1,89 điểm), Sự tham gia của PH (+1,73 điểm), Học vấn PH (+1,08 điểm), Bạn bè (+1,06 điểm), Thu nhập (+0,99 điểm), Động lực (+0,95 điểm), Chất lượng GV (+0,93 điểm), Ngoại khóa (+0,51 điểm).

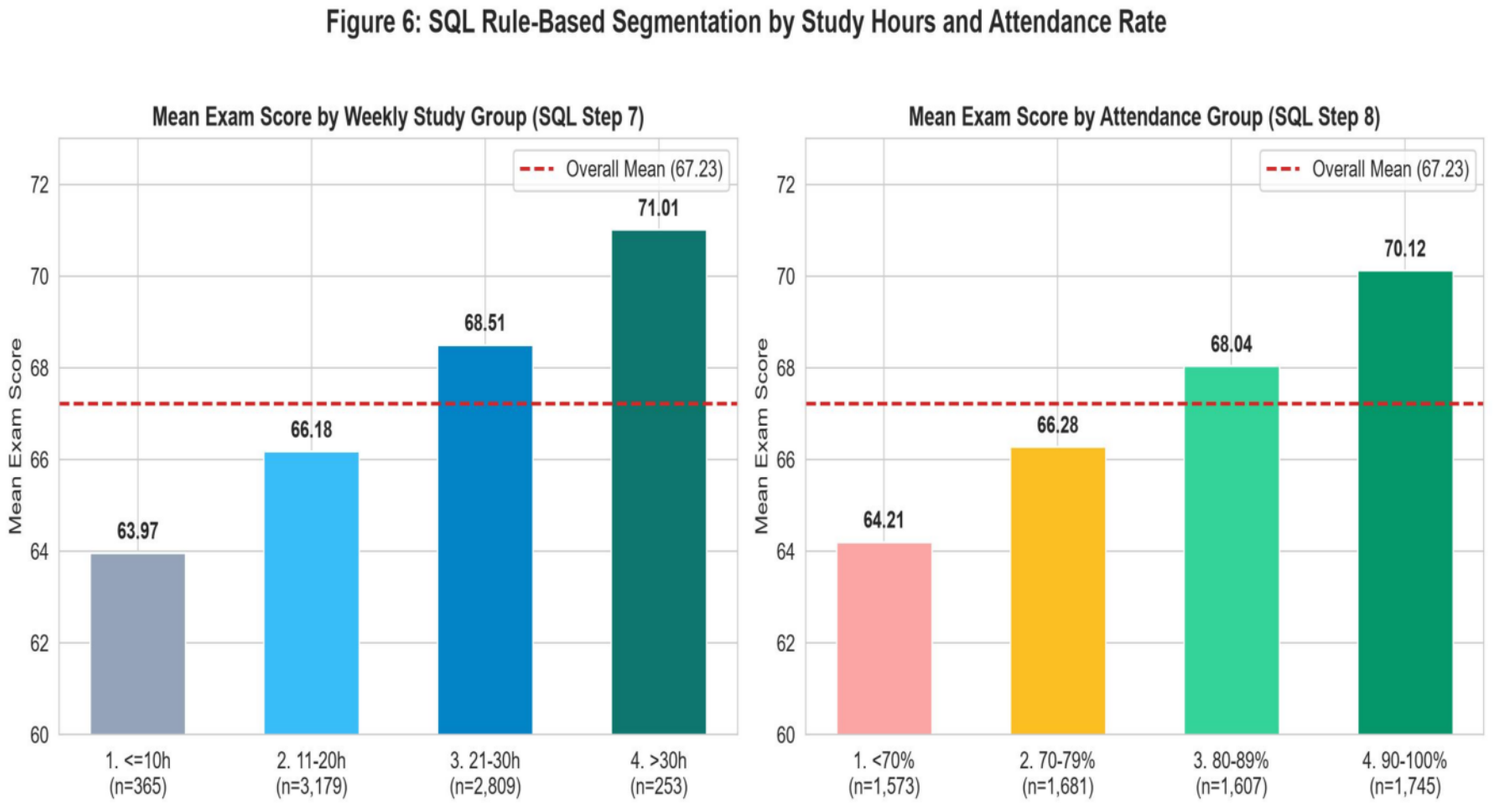
- Không có sự khác biệt: Giới tính (p = 0,869) và Loại trường (p = 0,472).

Tài nguyên học tập, sự đồng hành của phụ huynh và môi trường bạn bè tích cực nâng cao điểm số rõ rệt.

07

STEPS 7 & 8 — SQL MODELING

Bước 7 & 8: Mô Hình Phân Nhóm Quy Tắc Bằng SQL



Kết Quả Phân Nhóm SQL

- Nhóm Giờ tự học (Bước 7):
  - <=10h (n=365): 63,97 (-3,26, Hạng 4)
  - 11-20h (n=3.179): 66,18 (-1,05, Hạng 3)
  - 21-30h (n=2.809): 68,51 (+1,28, Hạng 2)
  - >30h (n=253): 71,01 (+3,78, Hạng 1)

- Nhóm Chuyên cần (Bước 8):
  - Dưới 70% (n=1.573): 64,21
  - 70-<80% (n=1.681): 66,28
  - 80-<90% (n=1.607): 68,04
  - 90-100% (n=1.746): 70,12

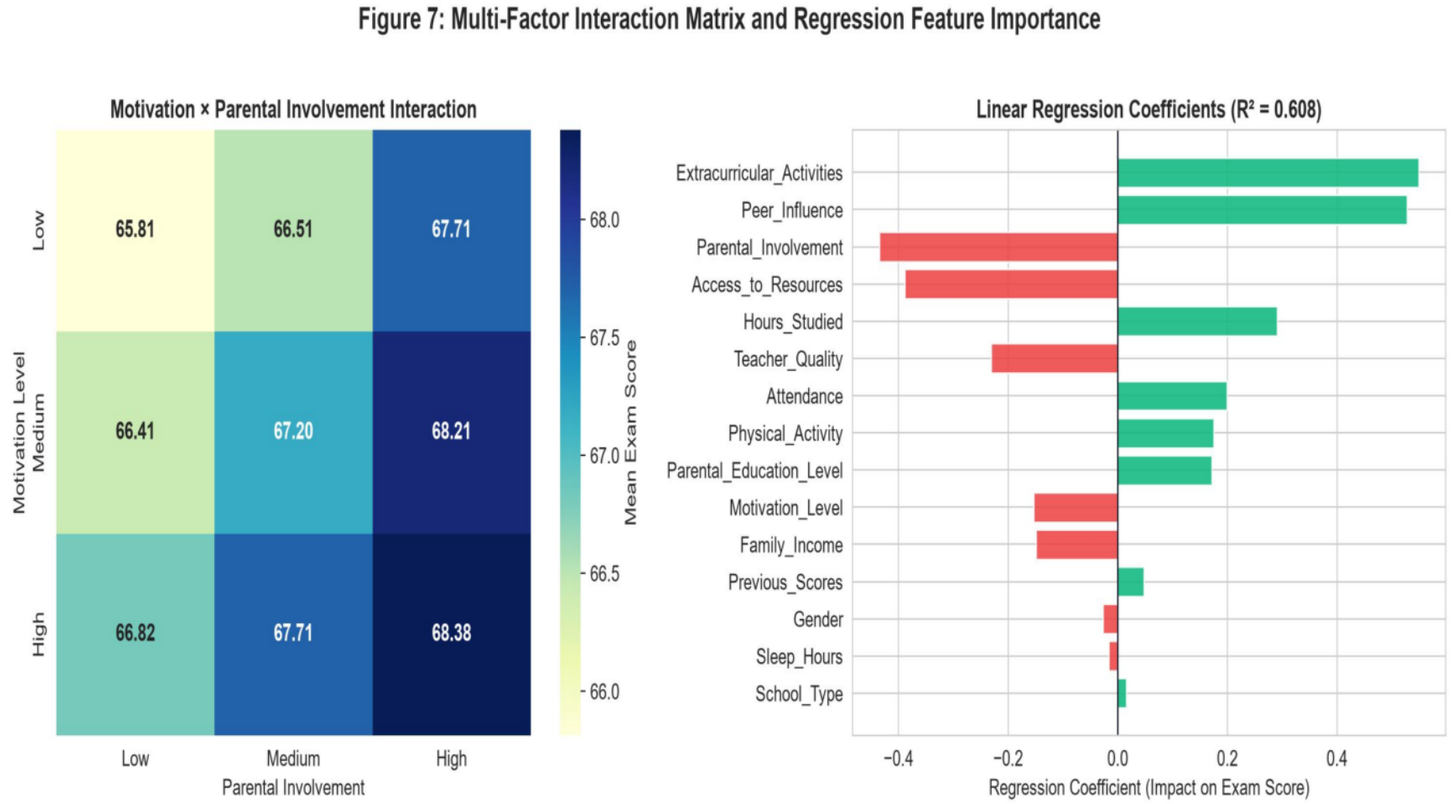
Kỹ thuật SQL: Kết hợp bảng tạm CTE (WITH grouped AS), biểu thức CASE WHEN và hàm cửa sổ RANK() OVER, SUM() OVER ().

Tăng thời lượng tự học từ <=10h lên >30h/tuần giúp điểm thi trung bình tăng thêm +7,04 điểm.

08

STATISTICAL & ML MODELING

Ma Trận Tương Tác & Mô Hình Hồi Quy Tuyến Tính



Kết Quả Mô Hình Hóa

- Động lực × Phụ huynh tham gia:
  - Low × Low: 65,81 điểm
  - Medium × Medium: 67,20 điểm
  - High × High: 68,38 điểm (+2,57)

- Hồi quy tuyến tính đa biến:
  - Label-Encoded R^2 = 0,608 (60,8% phương sai)
  - One-Hot R^2 = 0,684 (68,4% phương sai)
  - Sai số MAE = 1,31 điểm.

Hiệu ứng cộng hưởng: Nỗ lực cá nhân (giờ học, điểm danh) kết hợp cùng động lực và sự quan tâm của phụ huynh tạo kết quả tối ưu.

Mô hình hồi quy đa biến giải thích tới 68,4% sự biến thiên điểm thi của sinh viên.

09

STEPS 8 TO 10 — CONCLUSION

Bước 8–10: Đánh Giá JOIN, Triển Khai & Khuyến Nghị

Bước 8: Đánh Giá Chuyên Sâu Bằng SQL CTE + JOIN

- CROSS JOIN (Học vấn PH × Ngoại khóa so với TB chung 67,23):
  - Sau ĐH + Có ngoại khóa (n=774): 68,15 (+0,92)
  - Cao đẳng/ĐH + Có ngoại khóa (n=1.208): 67,48 (+0,25)
  - THPT + Không ngoại khóa (n=1.317): 66,55 (-0,68)

- INNER JOIN (Top sinh viên vượt TB nhóm động lực):
  - student_id = 95 (Medium, Điểm = 100, vượt nhóm +32,67)
  - student_id = 2426 (Low, Điểm = 99, vượt nhóm +32,27)

Bước 9: Đóng Gói & Triển Khai Hệ Thống

- Cơ sở dữ liệu SQLite: student_analysis.db lưu trữ 3 bảng raw_students, students_clean_sql, students_clean_python.

- Kịch bản SQL độc lập: TruyVan_LamSach_PhanTich.sql (14 truy vấn chuẩn SQLite).

- 3 File CSV xuất tự động (chống lỗi khóa file Excel/OneDrive):
  - student_performance_cleaned_sql.csv
  - student_performance_cleaned_python.csv
  - analysis_study_groups.csv

Bước 10: Phản Hồi Cải Tiến & Khuyến Nghị Cho Nhà Trường

- 1. Quản trị dữ liệu: Xác minh lại với nguồn dữ liệu về bản ghi student_id = 1526 (Exam_Score = 101); chuẩn hóa biểu mẫu khảo sát để giảm ô trống.

- 2. Hệ thống cảnh báo sớm: Ưu tiên nhắc nhở và phụ đạo nhóm sinh viên có tỷ lệ điểm danh < 75% hoặc tự học <= 10 giờ/tuần.

- 3. Hỗ trợ toàn diện: Mở rộng tài nguyên học tập cho sinh viên thu nhập thấp, tăng cường kết nối với phụ huynh và khuyến khích hoạt động ngoại khóa.

Cảm Ơn Thầy Cô Và Các Bạn Đã Lắng Nghe! — Hoàn Tất Quy Trình 10 Bước Data Science Với SQL & Python