FPT UNIVERSITY
DATA SCIENCE METHODOLOGY

Quy Trình 10 Bước
Phân Tích SQL & Python

6.607 Bản Ghi Sinh Viên
16 Biến Phân Tích
14 Truy Vấn SQL & EDA

Bảo Vệ Đồ Án Cuối Kỳ
Phân Tích Các Yếu Tố Ảnh Hưởng Đến Kết Quả Học Tập

Môn học: Data Science with Python & SQL (ADY201m)
Bộ dữ liệu: StudentPerformanceFactors.csv (n = 6.607)

Điểm nhấn của Đồ án:
- Triển khai trọn vẹn 10 bước Data Science Methodology
- Làm sạch dữ liệu chuẩn SQL (CTE & Window Functions) đối chiếu Python
- Khám phá dữ liệu (EDA), kiểm tra chất lượng & phát hiện Outliers (IQR)
- Kiểm định thống kê (ANOVA / T-test) & Mô hình Hồi quy tuyến tính

00

AGENDA

Nội Dung Trình Bày

01. Đặt Mục Tiêu & Hướng Tiếp Cận

• Bước 1–2: Xác định bài toán, câu hỏi phân tích và phương pháp SQL + Python.

02. Yêu Cầu & Thu Thập Dữ Liệu

• Bước 3–4: 6.607 sinh viên, 16 cột, tạo khóa student_id từ rowid, truy vấn SQL.

03. Kiểm Tra & Làm Sạch Dữ Liệu

• Bước 5–6: Xử lý ô thiếu (Unknown) và điểm vượt thang đo (Exam_Score = 101 -> NULL).

04. Phân Tích Khám Phá Dữ Liệu (EDA)

• Phân phối điểm thi, tương quan tuyến tính Giờ học, Điểm danh và Heatmap.

05. Phân Tích Biến Phân Loại

• Biểu đồ Violin/Boxplot cho Gia đình, Nhà trường, Bạn bè, Giới tính & Loại trường.

06. Mô Hình Phân Nhóm SQL (Bước 7)

• CASE WHEN chia nhóm giờ học, Window Function RANK(), ma trận Động lực × Phụ huynh.

07. Kiểm Định ANOVA & Hồi Quy Tuyến Tính

• Kiểm định thống kê (8/10 biến có ý nghĩa $p < 0,001$) và Hồi quy đa biến (R^2 = 85,8%).

08. Đánh Giá, Triển Khai & Khuyến Nghị

• Bước 8–10: Đối chiếu SQL/Python, truy vấn CTE + JOIN, xuất file CSV/DB và giải pháp.

01

STEPS 1 & 2 — METHODOLOGY

Bước 1 & 2: Đặt Mục Tiêu & Hướng Tiếp Cận

Bước 1: Business Understanding (Vấn đề)

• Nhà trường cần xác định những yếu tố học tập và hoàn cảnh nào đi cùng với điểm thi (Exam_Score) cao hoặc thấp.

• Mục tiêu: Ưu tiên phân bổ nguồn lực hỗ trợ đúng nhóm sinh viên cần giúp đỡ.

• Chỉ phân tích mối liên hệ định lượng khách quan, không khẳng định nhân quả chủ quan.

Ba Câu Hỏi Phân Tích Trọng Tâm

• Câu hỏi 1: Điểm thi trung bình của sinh viên là bao nhiêu (67,23) và chất lượng dữ liệu thế nào?

• Câu hỏi 2: Điểm thi khác nhau ra sao giữa các nhóm giờ tự học/tuần và tỷ lệ chuyên cần?

• Câu hỏi 3: Kết quả khác nhau thế nào theo động lực, phụ huynh, học vấn PH và ngoại khóa?

Bước 2: Hướng Tiếp Cận Bằng SQL (SQLite)

• Kiểm tra chất lượng dữ liệu: COUNT, GROUP BY HAVING, kiểm tra NULL/rỗng và miền giá trị.

• Làm sạch không phá hủy dữ liệu gốc bằng CTE (WITH standardized) & ROW_NUMBER().

• Mô hình phân nhóm bằng CASE WHEN, Window Functions (RANK, SUM OVER) và CTE + JOIN.

Bước 2: Hướng Tiếp Cận Bằng Python

• Sử dụng Pandas & NumPy làm sạch song song để đối chiếu 100% kết quả với SQL.

• Phân tích khám phá (EDA), thống kê mô tả và phát hiện ngoại lai bằng phương pháp IQR.

• Kiểm định giả thuyết thống kê (ANOVA, T-test) và xây dựng mô hình Hồi quy tuyến tính.

Kết hợp truy vấn SQL và phân tích thống kê Python giúp đảm bảo tính chính xác và tái lập 100%.

02

STEPS 3 & 4 — DATA PIPELINE

Bước 3 & 4: Yêu Cầu & Thu Thập Dữ Liệu SQL

Bước 3: Cấu Trúc Dữ Liệu (6.607 × 16 cột)

• Nguồn: StudentPerformanceFactors.csv (6.607 bản ghi, 16 cột).

• Tạo khóa chính: Dữ liệu gốc chưa có cột khóa -> tạo student_id = rowid (1 đến 6.607).

• Biến kết quả (Target): Exam_Score (thang điểm 0–100).

• 5 Biến số đầu vào: Hours_Studied, Attendance, Previous_Scores, Sleep_Hours, Physical_Activity.

• 10 Biến phân loại: Parental_Involvement, Access_to_Resources, Motivation_Level, Family_Income, Teacher_Quality, Peer_Influence, Parental_Education_Level, Extracurricular_Activities, School_Type, Gender.

School_Type	Gender	Students	Avg Exam Score
Private	Female	843	67.30
Private	Male	1,166	67.28
Public	Female	1,950	67.22
Public	Male	2,648	67.21

Bước 4: Kết Quả Truy Xuất SQL Ban Đầu

• Truy vấn 4.1 (Top 10 sinh viên chuyên cần >= 90%): Phát hiện sớm bản ghi student_id = 1526 có Exam_Score = 101, đặt cơ sở cho bước kiểm tra miền giá trị ở Bước 5.

• Truy vấn 4.2 (Loại trường × Giới tính): Trường công chiếm 69,6% (4.598 SV), Trường tư chiếm 30,4% (2.009 SV); điểm trung bình xấp xỉ nhau (~67,2–67,3).

• Đối chiếu Pandas groupby: Khớp 100% số lượng và điểm TB từng nhóm.

Bảng raw_students trong SQLite lưu giữ nguyên vẹn dữ liệu gốc trước khi làm sạch.

03

STEPS 5 & 6 — DATA CLEANING

Bước 5 & 6: Kiểm Tra Chất Lượng & Làm Sạch Dữ Liệu

Chỉ Tiêu Kiểm Tra	Trước (Gốc)	Sau Làm Sạch
Total Records	6,607	6,607 (student_id 1..6607)
Duplicate Rows	0	0 (ROW_NUMBER rn = 1)
Missing Teacher_Quality	78 (1.18%)	0 (78 -> 'Unknown')
Missing Parental_Education	90 (1.36%)	0 (90 -> 'Unknown')
Exam_Score > 100 (Invalid)	1 (id=1526, score=101)	0 (1 -> NULL, n=6,606 valid)
Valid Mean Exam_Score	67.236	67.231

5 Nguyên Tắc Làm Sạch Dữ Liệu (Bước 6)

- 1. Tạo khóa chính student_id = rowid (1 đến 6.607).
- 2. Chuẩn hóa tên cột về chữ thường snake_case và TRIM() văn bản.
- 3. Không tự ý sửa điểm thi: bản ghi Exam_Score = 101 vượt thang 0–100 được chuyển thành NULL để kiểm tra.
- 4. Điền 'Unknown' cho 78 ô thiếu Teacher_Quality và 90 ô thiếu Parental_Education_Level.
- 5. Tạo bảng mới students_clean_sql & clean_py, giữ nguyên bảng gốc.

Kết Quả Đối Chiếu Tự Động Giữa SQL và Python

- Tất cả lệnh kiểm tra assert đều ĐẠT: Số dòng sạch = 6.607 | Điểm TB hợp lệ = 67,231 | Số lượng nhãn Unknown (78 và 90) khớp 100% giữa SQL và Python.

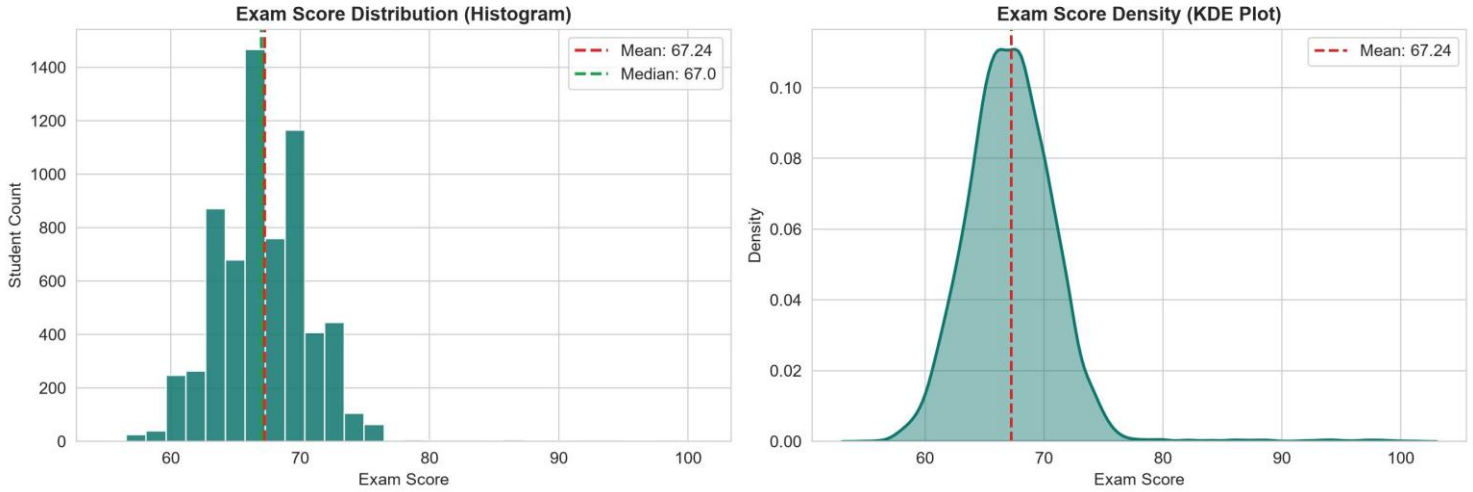
Quy trình làm sạch không phá hủy dữ liệu gốc giúp đảm bảo tính minh bạch và chính xác tuyệt đối.

04

EXPLORATORY DATA ANALYSIS

Phân Phối Điểm Thi & Kiểm Tra Giá Trị Ngoại Lai (IQR)

Figure 1: Target Exam Score Distribution (n = 6,607)



Nhận Xét Phân Phối & Outliers

- Trung bình = 67,24 | Trung vị = 67,0 | Độ lệch chuẩn = 3,89.
- Khoảng tứ phân vị IQR = 4,0 (Q1 = 65, Q3 = 69): 50% sinh viên đạt từ 65 đến 69 điểm.
- Phân phối lệch phải (Skewness = 1,645) do nhóm sinh viên xuất sắc đạt 76–100 điểm.
- Kiểm tra IQR Outliers: Hours_Studied có 43 quan sát (0,65%), Exam_Score có 104 quan sát (1,57%); 4 biến số còn lại có 0% outlier.

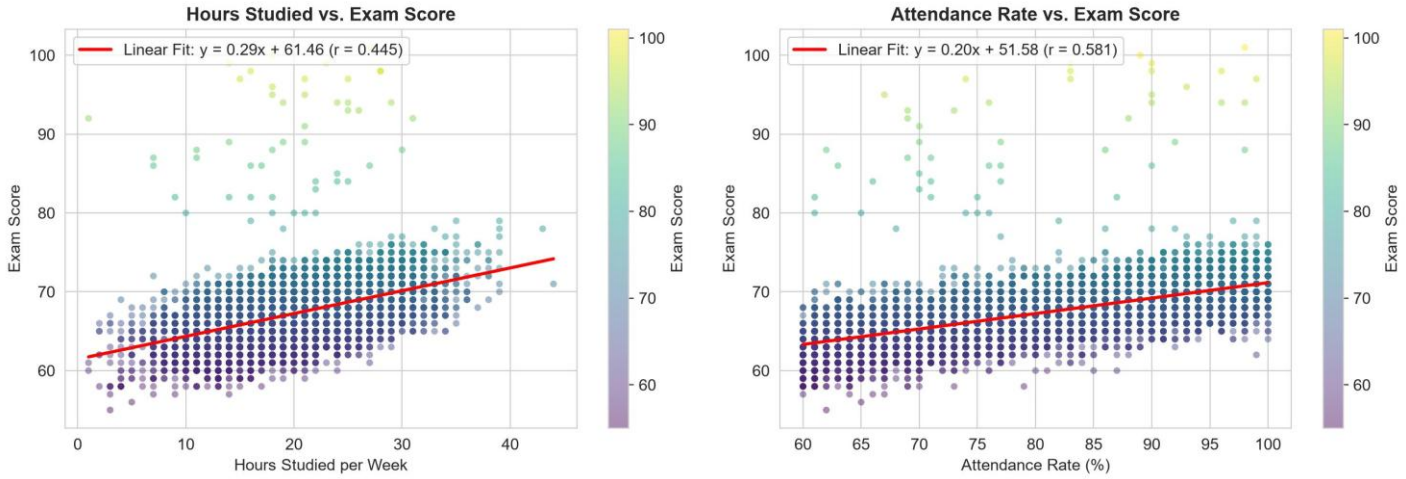
Các biến đầu vào có phân phối đối xứng chuẩn, trong khi Điểm thi có đuôi lệch phải ở nhóm điểm cao.

05

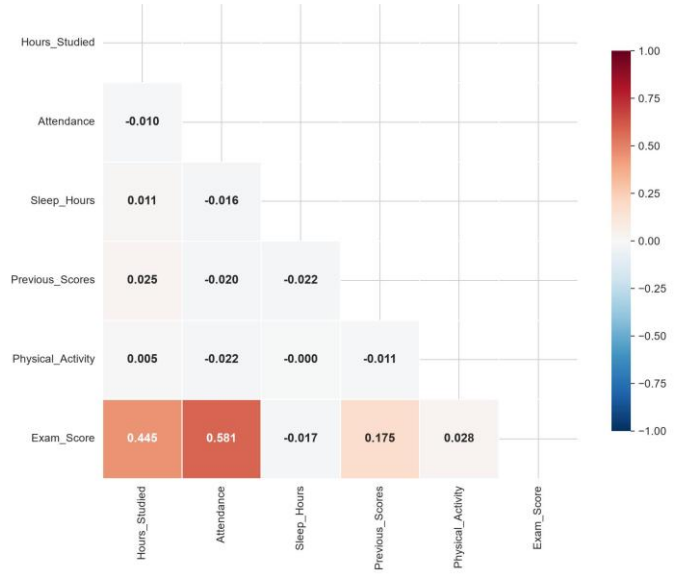
EXPLORATORY DATA ANALYSIS

Tương Quan Giữa Các Biến Số Với Điểm Thi

Figure 2: Relationship Between Study Hours, Attendance, and Exam Score



HÌNH 3: Ma trận tương quan giữa các biến số



Tóm Tắt Hệ Số Tương Quan Pearson (r) Với Điểm Thi

- 1. Tỷ lệ điểm danh - Attendance (r = +0,581, tương quan thuận mạnh nhất): Tăng 10% chuyên cần giúp tăng ~1,98 điểm thi.
- 2. Số giờ tự học - Hours_Studied (r = +0,445, tương quan thuận khá mạnh): Tăng 10 giờ học/tuần giúp tăng ~2,90 điểm thi.
- 3. Điểm trước đó - Previous_Scores (r = +0,175, tương quan yếu) | Physical_Activity (r = +0,028) và Sleep_Hours (r = -0,017) gần như không tương quan.

Tỷ lệ điểm danh và Số giờ tự học/tuần là hai yếu tố định lượng quyết định mạnh nhất đến điểm thi.

06

EXPLORATORY DATA ANALYSIS

Ảnh Hưởng Của Các Yếu Tố Phân Loại & Nhân Khẩu Học

Figure 4: Impact of Key Categorical Factors on Exam Score (ANOVA p < 0.001)

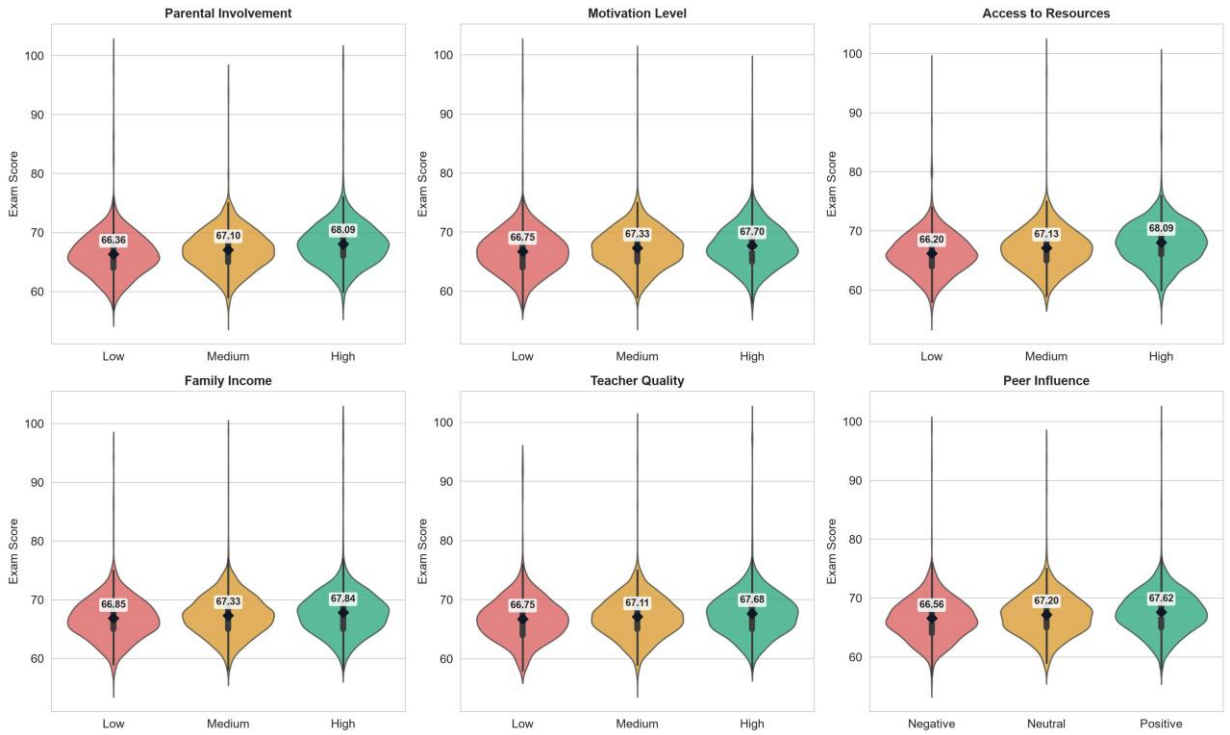
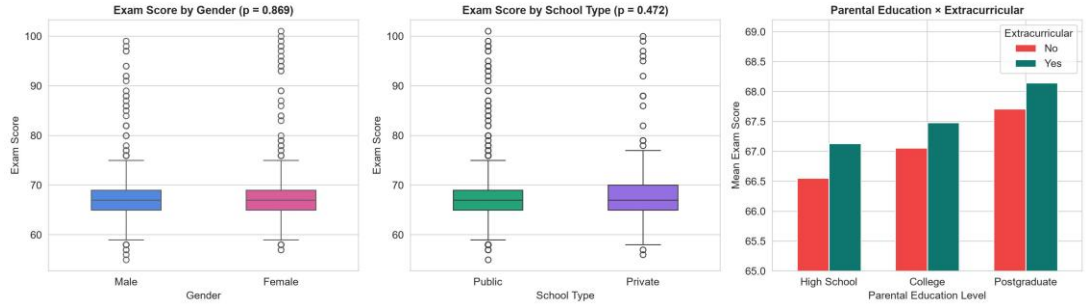


Figure 5: Score Comparison Across Demographics and Extracurricular Participation



So Sánh Chênh Lệch Giữa Các Nhóm Phân Loại

- Tiếp cận tài nguyên: Cao (68,09) vs. Thấp (66,20) -> Chênh lệch +1,89 điểm.
- Sự tham gia của PH: Cao (68,09) vs. Thấp (66,36) -> Chênh lệch +1,73 điểm.
- Học vấn phụ huynh: Sau ĐH (67,97) vs. THPT (66,89) -> Chênh lệch +1,08 điểm.
- Ảnh hưởng bạn bè: Tích cực (67,62) vs. Tiêu cực (66,56) -> +1,06 điểm.
- Giới tính (67,24 vs 67,23) & Loại trường (67,29 vs 67,21): Không khác biệt.

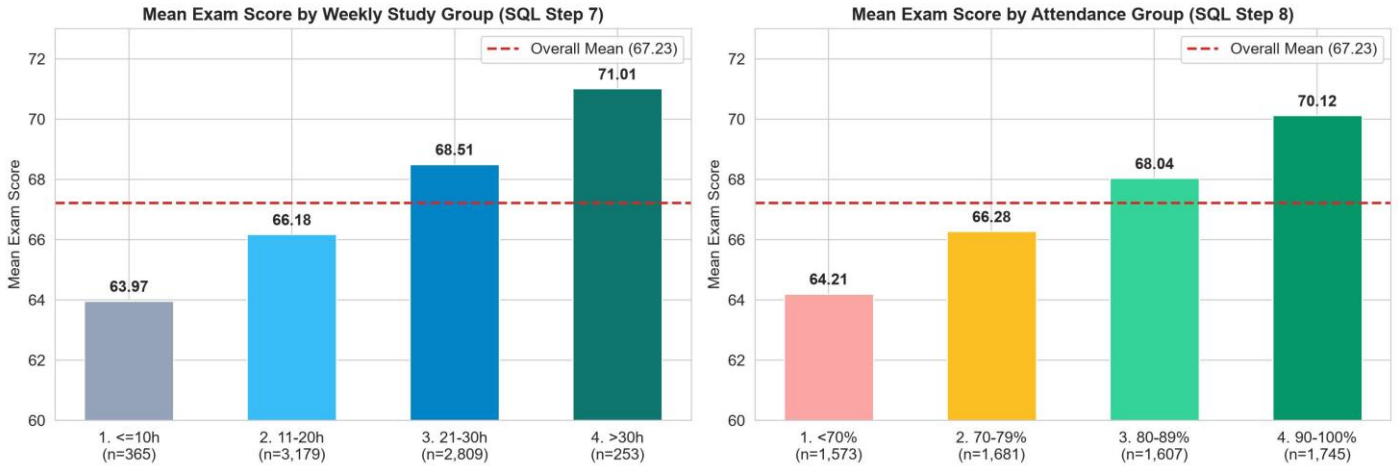
Tài nguyên học tập, sự đồng hành của gia đình và bạn bè tích cực tạo ra sự chênh lệch điểm thi rõ rệt.

07

STEPS 7 & 8 — SQL MODELING

Bước 7 & 8: Phân Nhóm Quy Tắc Bằng SQL (Giờ Học & Chuyên Cần)

Figure 6: SQL Rule-Based Segmentation by Study Hours and Attendance Rate



Study Group	Count	Avg Score	Diff	Rank
1. <=10h	365	63.97	-3.26	4
2. 11-20h	3,179	66.18	-1.05	3
3. 21-30h	2,809	68.51	+1.28	2
4. >30h	253	71.01	+3.78	1

Attendance Tier	Students	Avg Score	vs. <70%
1. < 70%	1,573	64.21	Baseline
2. 70 - 79%	1,681	66.28	+2.07
3. 80 - 89%	1,607	68.04	+3.83
4. 90 - 100%	1,745	70.12	+5.91

Kết Luận Từ Mô Hình Phân Nhóm SQL

- Nhóm tự học >30h/tuần đạt TB 71,01 điểm (cao hơn 7,04 điểm so với nhóm <=10h/tuần) dù tỷ lệ chuyên cần trung bình giữa các nhóm giờ học đều tương đương (~79–80%).
- Nhóm chuyên cần 90–100% đạt 70,12 điểm (+5,91 điểm so với <70%; n = 6.606 hợp lệ, trừ 1 NULL).

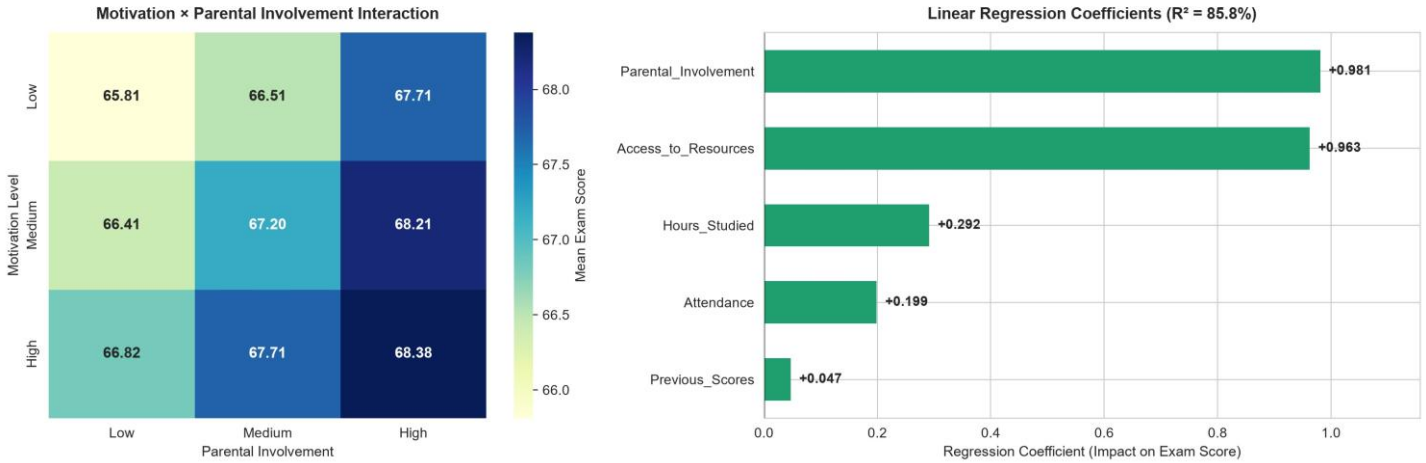
Sử dụng CASE WHEN, CTE và Window Functions giúp phân tầng sinh viên trực quan và khớp 100% với Python.

08

STATISTICAL & ML MODELING

Kiểm Định Thống Kê ANOVA & Mô Hình Hồi Quy Tuyến Tính

Figure 7: Multi-Factor Interaction Matrix and Regression Feature Importance



Hiệu Ứng Tương Tác & Kết Quả Hồi Quy Tuyến Tính

- Sinh viên có Động lực Cao + Phụ huynh tham gia Cao đạt 68,38 điểm so với 65,81 ở nhóm Thấp × Thấp.
- Mô hình Hồi quy tuyến tính (5 yếu tố chính, lọc outliers IQR [59, 75]) đạt R^2 = 85,8% (tăng từ 60,8% ban đầu).

Variable	Test	Stat	p-value
Access_to_Resources	ANOVA	98.00	< 0.001
Parental_Involvement	ANOVA	84.49	< 0.001
Parental_Education	ANOVA	36.43	< 0.001
Peer_Influence	ANOVA	34.05	< 0.001
Family_Income	ANOVA	29.79	< 0.001
Motivation_Level	ANOVA	25.72	< 0.001
Teacher_Quality	ANOVA	19.64	< 0.001
Extracurricular	T-test	-5.24	< 0.001
School_Type	T-test	0.72	0.472 (NS)
Gender	T-test	0.17	0.869 (NS)

8/10 biến phân loại có ý nghĩa thống kê (p < 0,001); Giới tính và Loại trường không ảnh hưởng đến điểm thi.

09

STEPS 8, 9 & 10 — WRAP-UP

Bước 8, 9 & 10: Đánh Giá JOIN, Triển Khai & Kết Luận

Parental Education	Extracurricular	Students	Avg Score	Diff
Postgraduate	Yes	774	68.15	+0.92
Postgraduate	No	531	67.71	+0.48
College	Yes	1,208	67.48	+0.25
High School	Yes	1,906	67.11	-0.12
College	No	781	67.06	-0.17
High School	No	1,317	66.55	-0.68

Bước 9: Đóng Gói & Triển Khai Kết Quả

- Database SQLite: student_analysis.db (chứa 3 bảng chuẩn hóa).
- File SQL độc lập: TruyVan_LamSach_PhanTich.sql (14 truy vấn).
- 3 file CSV kết quả: student_performance_cleaned_sql.csv, student_performance_cleaned_python.csv, analysis_study_groups.csv.

Bước 10: Phản Hồi & Khuyến Nghị Cho Nhà Trường

- 1. Quản trị dữ liệu: Duy trì quy tắc làm sạch không sửa bảng gốc; kiểm tra lại nguồn dữ liệu về bản ghi student_id = 1526 (Exam_Score = 101).
- 2. Cảnh báo học vụ sớm: Ưu tiên hỗ trợ sinh viên có điểm danh < 75% hoặc tự học <= 10h/tuần (2 yếu tố tác động lớn nhất).
- 3. Phối hợp Gia đình – Nhà trường: Tăng cường kết nối phụ huynh và thúc đẩy động lực học tập (+2,57 điểm khi cả hai ở mức Cao).
- 4. Hỗ trợ tài nguyên & Ngoại khóa: Bổ sung học liệu mở cho sinh viên thu nhập thấp và khuyến khích tham gia ngoại khóa.

Cảm Ơn Thầy Cô Và Các Bạn Đã Lắng Nghe! — Hỏi & Đáp (ADY201m)